Warsztaty z technik uczenia maszynowego

Predykcja sprzedaży w sklepach detalicznych w Ekwadorze

Grupa 12:

- Milena Zacharczuk
- Jan Gryczka
- Maciej Bandurow
- Norbert Dzadz

Wczytanie bibliotek

```
import numpy as np
import pandas as pd
import matplotlib.pyplot as plt
import statsmodels
import statsmodels.api as sm
import statsmodels.formula.api as smf
import datetime as dt
import scipy.signal as ss
import xgboost as xgb
from sklearn.tree import DecisionTreeRegressor
import group_lasso
from sklearn.metrics import mean_squared_error
import os
import plotly.express as px
import plotly.graph_objects as go
```

Ścieżka z modelami

```
ROOT = "C:\\Users\\grycz\\Studia\\Magisterka\\II semestr 2021-2022\\WzTUM\WTUM_12_2022\\"
```

Wczytanie zbiorów

```
holidays_events = pd.read_csv("https://www.dropbox.com/s/bxyamlpevkiwwoq/holidays_events.csv?dl=1")
holidays_events["holiday_type"] = holidays_events["type"]
holidays_events.drop(["type"],axis=1,inplace=True)
oil = pd.read_csv("https://www.dropbox.com/s/l6ln0ztl4m0pw3a/oil.csv?dl=1",parse_dates=['date'],index_col='date')
oil2 = pd.read_csv("https://www.dropbox.com/s/l6ln0ztl4m0pw3a/oil.csv?dl=1")
sample_submission = pd.read_csv("https://www.dropbox.com/s/68jjl61x6u3klos/sample_submission.csv?dl=1")
stores = pd.read_csv("https://www.dropbox.com/s/lcxn6r9bs2exguq/stores.csv?dl=1")
test = pd.read_csv("https://www.dropbox.com/s/cvdo1gn7r5lu2uz/test.csv?dl=1",index_col='id')
train = pd.read_csv("https://www.dropbox.com/s/s8p2b5awnuqfk0d/train.csv?dl=1",index_col='id')
transactions = pd.read_csv("https://www.dropbox.com/s/92fij9bcwt0e0cj/transactions.csv?dl=1")
```

Data Quality Check

```
import warnings
warnings.filterwarnings("ignore")
```

Zbiór holidays_events zawiera informacje o świętach. date - data święta (od 2012-03-02 do 2017-12-26) type - typ święta: Addition, Bridge, Event, Transfer, Holiday, Work Day locale - Local, National, Regional locale_name - nazwa jednostki administracyjnej odpowiedniej dla zmiennej 'locale' description - opis święta transferred - zmienna binarna, gdy święto zostało przesunięte na inny dzień

```
holidays_events.head(10)
```

	date	locale	locale_name	description	transferred	holiday_type
0	2012-03-02	Local	Manta	Fundacion de Manta	False	Holiday
1	2012-04-01	Regional	Cotopaxi	Provincializacion de Cotopaxi	False	Holiday
2	2012-04-12	Local	Cuenca	Fundacion de Cuenca	False	Holiday
3	2012-04-14	Local	Libertad	Cantonizacion de Libertad	False	Holiday
4	2012-04-21	Local	Riobamba	Cantonizacion de Riobamba	False	Holiday
5	2012-05-12	Local	Puyo	Cantonizacion del Puyo	False	Holiday
6	2012-06-23	Local	Guaranda	Cantonizacion de Guaranda	False	Holiday
7	2012-06-25	Regional	Imbabura	Provincializacion de Imbabura	False	Holiday
8	2012-06-25	Local	Latacunga	Cantonizacion de Latacunga	False	Holiday
9	2012-06-25	Local	Machala	Fundacion de Machala	False	Holiday

Zbiór oil zawiera informacje o cenach ropy. date - data raportu (od 2013-01-01 do 2017-08-31) dcoilwtico - cena ropy w dolarach

```
oil.head()
```

date	dcoilwtico
2013-01-01	NaN
2013-01-02	93.14
2013-01-03	92.97
2013-01-04	93.12
2013-01-07	93.20

Zbiór sample_submission to zbiór techniczny

Zbiór stores zawiera informacje o sklepach: store_nbr - id sklepu city - miasto lokalizacji state - stan type - rodzaj sklepu: A, B, C, D, E cluster - grupa podobnych sklepów

```
stores.head()
```

	store_nbr	city	state	type	cluster
0	1	Quito	Pichincha	D	13
1	2	Quito	Pichincha	D	13
2	3	Quito	Pichincha	D	8
3	4	Quito	Pichincha	D	9
4	5	Santo Domingo	Santo Domingo de los Tsachilas	D	4

Zbiór test zawiera informacje o zakupionych produktach:

1. id - id produktu
2. date - data sprzedaży (pierwsza data 15 dni od ostatniej daty ze zbioru train)
3. store_nbr - id sklepu
4. family - rodzaj zakupionej rzeczy
5. onpromotion - liczba produktów w danej 'family' na promocji w dnaym sklepie w danym sklepie

```
test.head(10)
```

id	date	store_nbr	family	onpromotion
3000888	2017-08-16	1	AUTOMOTIVE	0
3000889	2017-08-16	1	BABY CARE	0
3000890	2017-08-16	1	BEAUTY	2
3000891	2017-08-16	1	BEVERAGES	20
3000892	2017-08-16	1	BOOKS	0
3000893	2017-08-16	1	BREAD_BAKERY	12
3000894	2017-08-16	1	CELEBRATION	0
3000895	2017-08-16	1	CLEANING	25
3000896	2017-08-16	1	DAIRY	45
3000897	2017-08-16	1	DELI	18

Zbiór train zawiera informacje o zakupionych produktach:

1. id - id produktu
2. date - data sprzedaży
3. store_nbr - id sklepu
4. family - rodzaj zakupionej rzeczy
5. sales - liczba zakupionych produktów z danej 'family' w danym dniu i sklepie
6. onpromotion - liczba produktów w danej 'family' na promocji w danym dniu i sklepie

```
train.tail(10)
```

id	date	store_nbr	family	sales	onpromotion
3000878	2017-08-15	9	MAGAZINES	11.000	0
3000879	2017-08-15	9	MEATS	449.228	0
3000880	2017-08-15	9	PERSONAL CARE	522.000	11
3000881	2017-08-15	9	PET SUPPLIES	6.000	0
3000882	2017-08-15	9	PLAYERS AND ELECTRONICS	6.000	0
3000883	2017-08-15	9	POULTRY	438.133	0
3000884	2017-08-15	9	PREPARED FOODS	154.553	1
3000885	2017-08-15	9	PRODUCE	2419.729	148
3000886	2017-08-15	9	SCHOOL AND OFFICE SUPPLIES	121.000	8
3000887	2017-08-15	9	SEAFOOD	16.000	0

Zbiór transactions zawiera informacje o liczbie transakcji w danym sklepie i dniu: data - data store_nbr - id sklepu transactions - liczba transakcji

```
transactions.head(10)
```

	date	store_nbr	transactions
0	2013-01-01	25	770
1	2013-01-02	1	2111
2	2013-01-02	2	2358
3	2013-01-02	3	3487
4	2013-01-02	4	1922
5	2013-01-02	5	1903
6	2013-01-02	6	2143
7	2013-01-02	7	1874
8	2013-01-02	8	3250
9	2013-01-02	9	2940

```
#Funkcja pomocniczna do rysowania wykresów
def plot_df(df, x, y, title="", xlabel='Date', ylabel='Value', dpi=100, axiscolor ='black'):
    plt.figure(figsize=(16,5), dpi=dpi)
    plt.plot(x, y, color='tab:blue')
    plt.gca().set(title=title, xlabel=xlabel, ylabel=ylabel)
    plt.gca().title.set_color(axiscolor)
    plt.gca().xaxis.label.set_color(axiscolor)
    plt.gca().yaxis.label.set_color(axiscolor)
    plt.tick_params(colors=axiscolor, which='both')
    plt.show()
```

```
plot_df(oil,x=oil.index, y=oil.dcoilwtico, title='Ceny ropy', axiscolor='black')
```

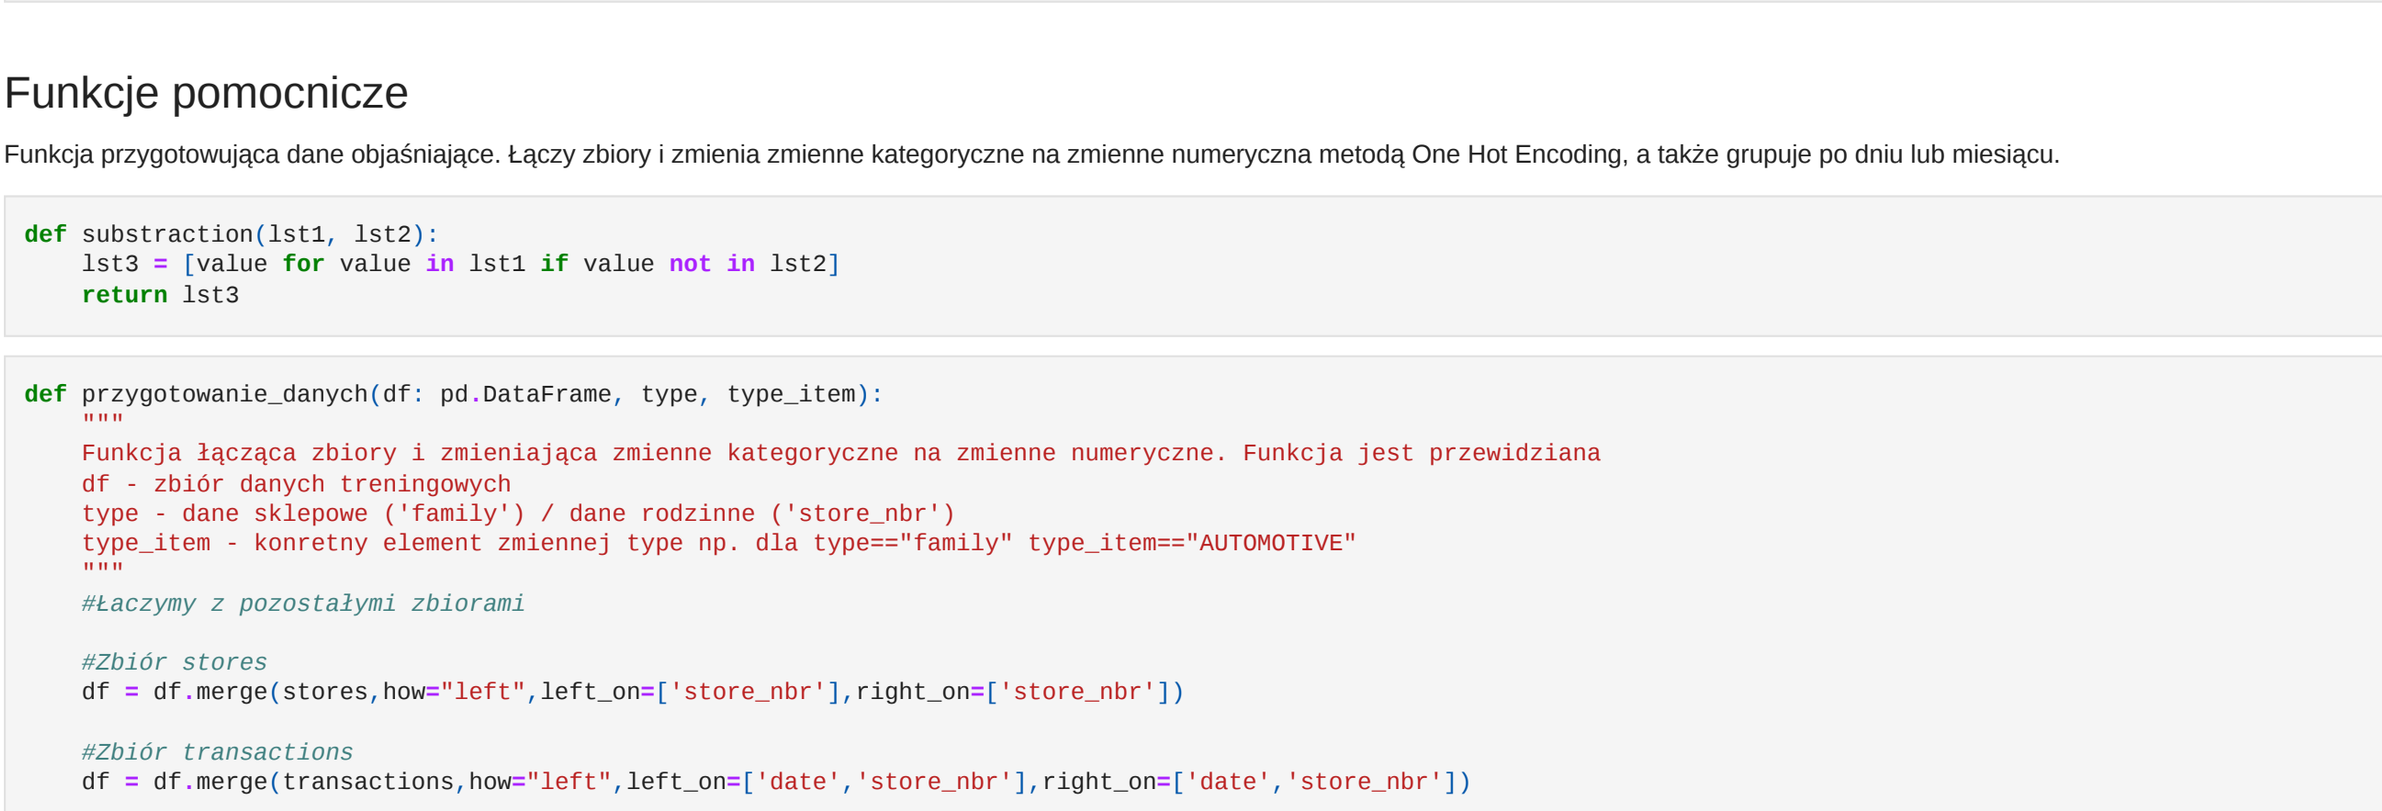

Wizualizacja danych treningowych:

1. Wykres liczby sprzedanych artykułów w zależności od daty i w podziale na rodzaj artykułu

```
fig = px.line(train, x='date', y='sales', color='family')
fig.show()
```

2. Wykres liczby sprzedanych artykułów w zależności od daty i w podziale na numer sklepu

```
fig = px.line(train, x='date', y='sales', color='store_nbr')
fig.show()
```

Funkcje pomocnicze

Funkcja przygotowująca dane objaśniające. Łączy zbiory i zmienia zmienne kategoryczne na zmienne numeryczna metodą One Hot Encoding, a także grupuje po dniu lub miesiącu.

```
def substraction(lst1, lst2):
    lst3 = [value for value in lst1 if value not in lst2]
    return lst3
```

```
def przygotowanie_danych(df: pd.DataFrame, type, type_item):
    """
    Funkcja łącząca zbiory i zmieniająca zmienne kategoryczne na zmienne numeryczne. Funkcja jest przewidziana
    df - zbiór danych treningowych
    type - dane sklepowe ('family') / dane rodzinne ('store_nbr')
    type_item - konretny element zmiennej type np. dla type=="family" type_item=="AUTOMOTIVE"
    """
    #Łaczymy z pozostałymi zbiorami

    #Zbiór stores
    df = df.merge(stores,how="left",left_on=['store_nbr'],right_on=['store_nbr'])

    #Zbiór transactions
    df = df.merge(transactions,how="left",left_on=['date','store_nbr'],right_on=['date','store_nbr'])

    #Zbiór holidays_events
    df = df.merge(holidays_events,how="left",left_on=['date'],right_on=['date'])

    #Dodanie oil
    df = df.merge(oil2,how="left",left_on=['date'],right_on=['date'])

    #Interpolacja braków danych z oil
    df.interpolate(method ='linear', limit_direction ='backward', inplace=True)

    #Wybieramy family ze zbioru traningowego
    df_fam = df.loc[(df[type]==type_item)]

    #Dodajemy zmienne na dzień tygodnia i na miesiąc
    df_fam['dayofweek'] = pd.DatetimeIndex(df_fam['date']).dayofweek + 1
    df_fam['month'] = pd.to_datetime(df_fam['date']).dt.month

    #Usunięcie zmiennych, które nie będą zmieniane
    df_fam.drop([type,"description","transferred"],axis=1,inplace=True)
    if type == "family":
        type_opposite = "store_nbr"
    elif type == "store_nbr":
        type_opposite = "family"

    #One Hot Encoding
    df_fam = pd.get_dummies(df_fam,columns=["locale",type_opposite,"city", "state", "type", "cluster","locale_name", "holiday_type"],prefix=["locale",type_opposite,"city", "state", "type", "cluster","lo

    #W zbiorze test jest tylko jeden miesiąc dlatego musimy zrobić techniczny zabieg polegający na dodaniu kolumn z samymi zerami.
    if 'sales' not in df_fam.columns:
        missing_cols = substraction(przygotowanie_danych(train,type,type_item).columns,df_fam.columns)
        for i in missing_cols:
            df_fam[i] = 0

    return(df_fam)
```

```
def dane_drzewo(df: pd.DataFrame, type, type_item):
    df2 =df.copy()
    df2["family"], uniques=pd.factorize(df2["family"])
    df2["city"], uniques=pd.factorize(df2["city"])
    df2["state"], uniques=pd.factorize(df2["state"])
    df2["type"], uniques=pd.factorize(df2["type"])
    df2["locale"], uniques=pd.factorize(df2["locale"])
    df2["locale_name"], uniques=pd.factorize(df2["locale_name"])
    df2["holiday_type"], uniques=pd.factorize(df2["holiday_type"])
    df2.fillna(0,inplace=True)
```

Podział danych na część treningową i walidacyjną.

```
def podzial(df: pd.DataFrame, date='2016-06-01'):
    """
    Funkcja dzieli zbiór df na cześć treningową i walidacyjną względem date.
    """
    train = df.loc[(df['date']<date)].drop(["date"],axis=1)
    test = df.loc[(df['date']>=date)].reset_index(drop=True).drop(["date"],axis=1)
    return(train,test)
```

Modele

Model XGBoost

Idea metody polega na użyciu funkcjonalnej wersji algorytmu spadku gradientu. Algorytm:

1. Krok $m = 0 : F(x) = \mathrm{argmin}_\eta \sum_{i=1}^n L(y_i, \eta)$, gdzie $L(\cdot,\cdot)$ to funkcja straty.
2. Dla $m = 1, \dots, M$:
   A. Wyznacz pseudo rezidua: $r_{im} = -\nabla L(y_i, F_{m-1}(x_i))$.
   B. Dopasuj model (drzewo) h_m dla danych $(x_i, r_{im})_{i=1}^n$.
   C. Oblicz $\eta_m = \mathrm{argmin}_\eta \sum_{i=1}^n L(y_i, F_{m-1}(x_i) + \eta h_m(x_i))$.
   D. Wyznacz kolejny model: $F_m(x) = F_{m-1}(x) + \eta_m h_m(x)$.
3. Ostateczny model: $F_M(x)$.

W modelu stosujemy domyślne hiperparametry, czyli

- booster = gbtree (rodzaj modelu w każdej iteracji)
- $\eta = 0.3$
- max_depth $= 6$
- min_child_weight $= 1$
- tree_method = auto

```
def model_xgb(df1: pd.DataFrame,df2: pd.DataFrame, model_name: str):
    """
    Funkcja tworzy model XGBoost na danych df1 i waliduje na danych df2.
    """
    #Zbiory danych treningowy
    X = df1.drop(['sales'],axis=1).copy()
    Y = df1['sales'].copy()

    #Zbiory danych walidacyjnych
    X_val = df2.drop(['sales'],axis=1)
    Y_val = df2['sales'].copy()

    #Dopasowanie modelu
    model = xgb.XGBRegressor()
    model.fit(X,Y)
    Y_pred = model.predict(X_val)

    #RMSE - jakość dopasowania
    RMSE = mean_squared_error(Y_val,Y_pred,squared=False)/(np.mean(Y_val))
    print("Model: ", model_name, " RMSE: ",RMSE)

    sciezka = ROOT + model_name + ".txt"
    model.save_model(sciezka)
    return(RMSE)
```

Model regresji liniowej

$Y = X\beta + \varepsilon,$
gdzie X jest macierzą zmiennych objaśniających, β wektorem współczynników, a ε wektorem błędów.
Przy pomocy metody najmniejszych kwadratów wyznaczamy b_{MNK} tj. estymator β.
$b_{MNK} = (X^TX)^{-1}X^TY.$

```
def model_ols(df1: pd.DataFrame,df2: pd.DataFrame, model_name: str):
    """
    Funkcja tworzy model regresji liniowej metodą najmniejszych kwadratów na danych df1 i waliduje na danych df2.
    """
    #Zbiory danych treningowy
    X = df1.drop(['sales'],axis=1).copy()
    Y = df1['sales'].copy()

    #Zbiory danych walidacyjnych
    X_val = df2.drop(['sales'],axis=1)
    Y_val = df2['sales'].copy()

    #Dopasowanie modelu
    model = sm.OLS(Y,X).fit()

    Y_pred = model.predict(X_val)

    #RMSE - jakość dopasowania
    RMSE = mean_squared_error(Y_val,Y_pred,squared=False)/(np.mean(Y_val))
    print("Model: ", model_name, " RMSE: ",RMSE)

    return(RMSE)
```

Model drzewa regresyjnego

Drzewo regresyjne polega na wykonywaniu testu w każdym węźle, aby podzielić dane na dwie grupy.

Algorytm:

1. Proces zaczynamy w korzeniu.
2. W każdym węźle ykonujemy test, czyli wybieramy zmienną $x_j \in \{x_1, \dots, x_p\}$ oraz próg t lub podzbiór $\{a1, \dots, a_k\}$, który maksymalizuje Δ SSE $= \mathrm{SSE}_P - \frac{n_L}{n_P}\mathrm{SSE}_L - \frac{n_R}{n_P}\mathrm{SSE}_R$, gdzie P, L, R to oznaczenia węzłów PARENT, LEFT, RIGHT, n_P, n_L, n_R to ich odpowiednie liczności, SSE_P, SSE_L, SSE_P to ich odpowiednie SSE.
3. Jeśli warunek w węźle jest spełniony, to przesuwamy się do lewego poddrzewa, a pozostałe obserwacje do prawego poddrzewa.
4. Predykcja dla danej obserwacji x_o to średnia zmiennej y w węźle, który odpowiada x_0.

```
def model_tree(df1: pd.DataFrame,df2: pd.DataFrame, model_name: str):
    """
    Funkcja tworzy model drzewa regresyjnego na danych df1 i waliduje na danych df2.
    """
    #Zbiory danych treningowy
    X = df1.drop(['sales'],axis=1).copy()
    Y = df1['sales'].copy()

    #Zbiory danych walidacyjnych
    X_val = df2.drop(['sales'],axis=1)
    Y_val = df2['sales'].copy()

    #Dopasowanie modelu
    model = DecisionTreeRegressor().fit(X,Y)
    Y_pred = model.predict(X_val)

    #RMSE - jakość dopasowania
    RMSE = mean_squared_error(Y_val,Y_pred,squared=False)/(np.mean(Y_val))
    print("Model: ", model_name, " RMSE: ",RMSE)

    return(RMSE)
```

Model lassa grupowego

Główną ideą grupowego Lasso jest rozwiązanie poniższego problemu

$$\hat{\beta} = \mathrm{argmin}_\beta \left(\sum_{i=1}^n l\left(f\left(\beta, x_i\right), y_i\right) + \lambda \sum_{j=1}^G \sqrt{|j|} \cdot ||\beta(j)||_2 \right),$$

gdzie $\beta(j)$ jest wektorem współczynników odpowiadających $j-$tej grupie, $\lambda > 0$ parametrem odpowiadającym za wielkość kary, natomiast $|j|$ oznacza rozmiar $j-$tej grupy.

Grupy są naturalnie wyznaczone przez zmienne z OneHotEncoding np. dni tygodnia są w jednej grupie.

```
def model_group_lasso(df1,df2, model_name: str):
    """
    Funkcja tworzy model grupowego lasso na danych df1 i waliduje na danych df2.
    """
    #Zbiory danych treningowy
    X = df1.drop(['sales'],axis=1).copy()
    Y = df1['sales'].copy()

    #Zbiory danych walidacyjnych
    X_val = df2.drop(['sales'],axis=1)
    Y_val = df2['sales'].copy()

    #Grupy
    if len(df1.columns) == 153:
        grupy = [-1    ,-1    ,-1    ,-1    ,-1    ,1     ,1     ,1     ,2     ,2     ,2     ,2     ,2     ,2     ,2     ,2     ,2     ,2     ,2     ,2     ,2     ,2     ,2     ,2
    elif len(df1.columns) == 76:
        grupy = [-1    ,-1    ,-1    ,-1    ,-1    ,1     ,1     ,1     ,2     ,2     ,2     ,2     ,2     ,2     ,2     ,2     ,2     ,2     ,2     ,2     ,2     ,2     ,2     ,2

    #Dopasowanie modelu
    model = group_lasso.GroupLasso(groups=grupy).fit(X,Y)
    Y_pred = model.predict(X_val)

    #RMSE - jakość dopasowania
    RMSE = mean_squared_error(Y_val,Y_pred,squared=False)/(np.mean(Y_val))
    print("Model: ", model_name, " RMSE: ",RMSE)

    return(RMSE)
```

Funkcja do predykcji

```
def predykcja (df: pd.DataFrame, model: xgb.XGBRegressor, folder: str):
    """
    Funkcja wykonuje predykcje modelu model na zbiorze df i odpisuje w formacie .csv do folderu folder.
    """
    mod2 = xgb.XGBRegressor()
    mod2.load_model(ROOT+model+".txt")
    df_res =df.copy()
    pred = mod2.predict(df)
    df_res["sales_pred"] = pred
    pred_csv = df_res.to_csv(folder+model+".csv",index=False)

    return(pred_csv)
```

Przykłady

Zbiory dla przykładów.

```
(train2,test2) = podzial(przygotowanie_danych(train,'family','AUTOMOTIVE'),'2016-06-01')
```

```
(train3,test3) = podzial(przygotowanie_danych(train,'store_nbr',1),'2016-06-01')
```

XGBoost - przykłady

```
RMSE_xgb = model_xgb(train2,test2,"przykladowa_rodzina")
```

```
Model:  przykladowa_rodzina  RMSE:  0.6861653699517859
```

```
RMSE_xgb = model_xgb(train3,test3,"przykladowy_sklep")
```

```
Model:  przykladowy_sklep  RMSE:  0.619896168517665
```

OLS - przykłady

```
RMSE_ols = model_ols(train2,test2,"przykladowa_rodzina")
```

```
Model:  przykladowa_rodzina  RMSE:  0.55467843815865
```

```
RMSE_ols = model_ols(train3,test3,"przykladowy_sklep")
```

```
Model:  przykladowy_sklep  RMSE:  1.6345695406293494
```

Drzewa regresyjnego - przykłady

```
RMSE_tree = model_tree(train2,test2,"przykladowa_rodzina")
```

```
Model:  przykladowa_rodzina  RMSE:  0.5957776758879871
```

```
RMSE_tree = model_tree(train3,test3,"przykladowy_sklep")
```

```
Model:  przykladowy_sklep  RMSE:  2.0635414972567943
```

Grupowe Lasso - przykłady

```
RMSE_group_lasso = model_group_lasso(train2,test2,"przykladowa_rodzina")
```

```
Model:  przykladowa_rodzina  RMSE:  1.327302825425444
```

```
RMSE_group_lasso = model_group_lasso(train3,test3,"przykladowy_sklep")
```

```
Model:  przykladowy_sklep  RMSE:  2.296909491056904
```

Dla przykładowego sklepu i dla przykładowej rodziny produktów RMSE wychodzi najlepsze dla modelu XGBoost. W związku z tym tworzymy modele XGBoost dla każdego sklepu i dla każdej rodziny, a następnie predykcje na zbiorze test.

Model dla każdej rodziny.

Modele odpisywane są do ROOT - ścieżki podanej na początku.

```
families = np.array(train["family"].unique())
family_RMSEs = []
```

```
for i in families:
    (train2,test2) = podzial(przygotowanie_danych(train,'family',i),'2016-06-01')
    RMSE_xgb = model_xgb(train2,test2,i)
    family_RMSEs.append(RMSE_xgb)
```

```
Model:  AUTOMOTIVE  RMSE:  0.6861653699517859
Model:  BABY CARE  RMSE:  3.4948295658920756
Model:  BEAUTY  RMSE:  0.7205881764239868
Model:  BEVERAGES  RMSE:  0.31779410053589807
Model:  BOOKS  RMSE:  3.994430513647246
Model:  BREAD_BAKERY  RMSE:  0.2647430624584278
Model:  CELEBRATION  RMSE:  1.170489191002666
Model:  CLEANING  RMSE:  0.30010944377920146
Model:  DAIRY  RMSE:  0.22848451644533507
Model:  DELI  RMSE:  0.25711408962040116
Model:  EGGS  RMSE:  0.5358559262506273
Model:  FROZEN FOODS  RMSE:  1.183994333148741
Model:  GROCERY I  RMSE:  0.34631785551533845
Model:  GROCERY II  RMSE:  0.8921728224904292
Model:  HARDWARE  RMSE:  1.2474795856009246
Model:  HOME AND KITCHEN I  RMSE:  1.2312579643318984
Model:  HOME AND KITCHEN II  RMSE:  1.395166723816384
Model:  HOME APPLIANCES  RMSE:  2.027397594974563
Model:  HOME CARE  RMSE:  0.3832039660347386
Model:  LADIESWEAR  RMSE:  1.0003645281008315
Model:  LAWN AND GARDEN  RMSE:  1.5703395588668807
Model:  LINGERIE  RMSE:  1.6117339198708882
Model:  LIQUOR,WINE,BEER  RMSE:  0.8290302418644222
Model:  MAGAZINES  RMSE:  1.1906109680185522
Model:  MEATS  RMSE:  1.6282833264045566
Model:  PERSONAL CARE  RMSE:  0.3576669348686532
Model:  PET SUPPLIES  RMSE:  0.9998124164531473
Model:  PLAYERS AND ELECTRONICS  RMSE:  0.9308743132629435
Model:  POULTRY  RMSE:  0.4512945494247541
Model:  PREPARED FOODS  RMSE:  0.39388841380161443
Model:  PRODUCE  RMSE:  0.5170562314183837
Model:  SCHOOL AND OFFICE SUPPLIES  RMSE:  4.2863020410426875
Model:  SEAFOOD  RMSE:  0.4670894912793439
```

Predykcja dla każdej rodziny.

Predykcja odpisywana jest do ROOT - ścieżki podanej na początku.

```
time = dt.datetime.now().strftime("%Y_%m_%d-%H-%M-%S")
folder2 = ROOT+"predict_family_"+time+"/"
os.makedirs(folder2)
```

```
mod2 = xgb.XGBRegressor()
for i in families:
    t = przygotowanie_danych(test,"family",i)
    t.drop(["date","sales"],axis=1,inplace=True)
    mod2.load_model(ROOT+i+".txt")
    mod2.predict(test2.drop(["sales"],axis=1))
    predykcja(t,i,folder2)
```

Model dla każdego sklepu.

Modele odpisywane są do ROOT - ścieżki podanej na początku.

```
stores_nbr = np.array(train["store_nbr"].unique())
stores_nbr.sort()
stores_nbr_RMSEs = []
```

```
for i in stores_nbr:
    (train3,test3) = podzial(przygotowanie_danych(train,'store_nbr',i),'2016-06-01')
    RMSE_xgb = model_xgb(train3,test3,str(i))
    stores_nbr_RMSEs.append(RMSE_xgb)
```

```
Model:  1  RMSE:  0.619896168517665
Model:  2  RMSE:  1.202274661355835
Model:  3  RMSE:  0.638647309700973
Model:  4  RMSE:  0.6145011981779515
Model:  5  RMSE:  0.47481874747601516
Model:  6  RMSE:  0.5299957297301366
Model:  7  RMSE:  0.6251099201534565
Model:  8  RMSE:  0.568254479802705
Model:  9  RMSE:  0.7249683913445263
Model:  10  RMSE:  0.6463020048718219
Model:  11  RMSE:  0.5876590283466371
Model:  12  RMSE:  0.6673139636253228
Model:  13  RMSE:  0.6578999813581602
Model:  14  RMSE:  0.8180761879968402
Model:  15  RMSE:  0.6871555087511952
Model:  16  RMSE:  0.9739440071073864
Model:  17  RMSE:  0.6157637579617724
Model:  18  RMSE:  1.7489272545172625
Model:  19  RMSE:  0.5878623958669554
Model:  20  RMSE:  2.650757137101323
Model:  21  RMSE:  0.6844599029862781
Model:  22  RMSE:  0.7164486523438528
Model:  23  RMSE:  0.5712708856222253
Model:  24  RMSE:  0.7491045307930404
Model:  25  RMSE:  1.6216000322047128
Model:  26  RMSE:  1.3043151073088282
Model:  27  RMSE:  0.6134293749978919
Model:  28  RMSE:  0.5385021907096733
Model:  29  RMSE:  0.5810905996616296
Model:  30  RMSE:  1.0009509955777756
Model:  31  RMSE:  0.609214497372626
Model:  32  RMSE:  2.2929278273406752
Model:  33  RMSE:  0.6774743581338424
Model:  34  RMSE:  0.4714854204380597
Model:  35  RMSE:  1.5497650982978541
Model:  36  RMSE:  0.5676639975318678
Model:  37  RMSE:  0.5581387103527389
Model:  38  RMSE:  0.7317758067485328
Model:  39  RMSE:  1.6572875148750508
Model:  40  RMSE:  0.7067297614968358
Model:  41  RMSE:  0.8106927710395105
Model:  42  RMSE:  0.5830163934956129
Model:  43  RMSE:  0.7258145375453657
Model:  44  RMSE:  0.606741685850131
Model:  45  RMSE:  0.6553825312821749
Model:  46  RMSE:  0.6098458242407935
Model:  47  RMSE:  0.5830493522471408
Model:  48  RMSE:  0.5901298907652035
Model:  49  RMSE:  0.5997521718298406
Model:  50  RMSE:  0.5441228466375505
Model:  51  RMSE:  0.6019627553220429
Model:  52  RMSE:  4.749503195636123
Model:  53  RMSE:  0.6410138896771196
Model:  54  RMSE:  1.3890690232380771
```

Predykcja dla każdego sklepu.

Predykcje odpisywane są do ROOT - ścieżki podanej na początku.

```
t = przygotowanie_danych(test,"family","AUTOMOTIVE")
t.drop(["date","sales"],axis=1,inplace=True)
time = dt.datetime.now().strftime("%Y_%m_%d-%H-%M-%S")
folder2 = ROOT+"predict_store_nbr_"+time+"/"
os.makedirs(folder2)
```

```
mod2 = xgb.XGBRegressor()
for i in stores_nbr:
    t = przygotowanie_danych(test,"store_nbr",i)
    t.drop(["date","sales"],axis=1,inplace=True)
    mod2.load_model("Modele/Modele"+str(i)+".txt")
    mod2.predict(test3.drop(["sales"],axis=1))
    predykcja(t,str(i),folder2)
```

Wykres predykcji wraz z oryginalnymi danymi.

```
def wykres(nr: str, type: int, rodzaj: int):
    """
    @param family: kategoria dla której chcemy narysować wykres
    @param type: typ wykresu 1 - zwykły szereg czasowy; 2 - szereg czasowy z suwakiem; 3 - szereg czasowy z suwakiem i przyciskami
    @param rodzaj: 1 - sklep, 2 - rodzina
    """
    if type not in [1,2,3]:
        raise Exception("Podano błędny numer typu wykresu!")
    if rodzaj == 1:
        t = przygotowanie_danych(test,"store_nbr",nr)
        t = t.drop(["sales"],axis=1)
        temp = []
        for i in range(1,34):
            temp.append('family_'+test.family.reset_index(drop=True)[i-1])
        df = pd.read_csv("predict_store_nbr_2022_05_27-01-30-07/"+str(nr)+".csv")
        df['family'] =df.loc[:,temp].idxmax(1).str[7:].astype(str)
        df['date'] = t['date'].reset_index(drop=True)
        df = df.rename(columns={'sales_pred':'sales'})
        df = df[['sales','family','date']]
        train_df = train.loc[(train['store_nbr'] == nr)]
        train_df = train_df[['sales','family','date']].reset_index()
        df_concat = pd.concat([train_df,df], axis=0).drop(['id'],axis=1)
        df_concat = df_concat.groupby(['date'])['sales'].mean().to_frame()
        df_concat = df_concat.reset_index()
    if rodzaj == 2:
        t = przygotowanie_danych(test,"family",nr)
        t = t.drop(["sales"],axis=1)
        temp = []
        for i in range(1,55):
            temp.append('store_nbr_'+str(i))
        df = pd.read_csv("predict_2022_05_18-22-13-14/"+nr+".csv")
        df['store_nbr'] =df.loc[:,temp].idxmax(1)
        df['date'] = t['date'].reset_index(drop=True)
        df['store_nbr'] =df['store_nbr'].str[10:].astype(int)
        df = df.rename(columns={'sales_pred':'sales'})
        df = df[['sales','store_nbr','date']]
        train_df = train.loc[(train['family'] == nr)]
        train_df = train_df[['sales','store_nbr','date']].reset_index()
        df_concat = pd.concat([train_df,df], axis=0).drop(['id'],axis=1)
        df_concat = df_concat.groupby(['date'])['sales'].mean().to_frame()
        df_concat = df_concat.reset_index()
    if type == 1:
        fig = px.line(df_concat, x='date', y='sales', title = "Sprzedaż dla kategorii "+family)
        fig.show()
    elif type == 2:
        fig = px.line(df_concat, x='date', y='sales')
        fig.update_xaxes(rangeslider_visible=True)
        fig.show()
    else:
        fig = px.line(df_concat, x='date', y='sales')
        fig.update_xaxes(
            rangeslider_visible=True,
            rangeselector=dict(
                buttons=list([
                    dict(count=1, label="1m", step="month", stepmode="backward"),
                    dict(count=3, label="3m", step="month", stepmode="backward"),
                    dict(count=6, label="6m", step="month", stepmode="backward"),
                    dict(count=1, label="1y", step="year", stepmode="backward"),
                    dict(step="all")
                ])
            )
        )
        fig.show()
```

```
wykres("BABY CARE",3,2)
```

```
wykres(2,3,1)
```

Podsumowanie

Po przetestowaniu kilku modeli (ARMA, SARIMA, regresja liniowa, XGBoost, Grupowe Lasso, Drzewo Regresyjne). Zdecydowaliśmy się na wykorzystanie XGBoost, który dawał najlepsze rezultaty. Wyniki predykcji są uwarunkowane bardzo mocno od jakości danych. Wszystkie modele i predykcje odpisują się do folderu ROOT, więc kod jest zautomatyzowany.